경량화 기법을 적용한 MLP기반 IOT 침입 탐지 시스템 구현

프로젝트 기간	**25.03 ~ 25.05**
인원	3인
역할	데이터 전처리, 모델링,
기술스택	TensorFlow, Scikit learn, Pandas, numpy

목표

가정 및 산업용 IoT 기기 보급으로 개인정보 유출 및 해킹 사례 빈번하며,
IoT기기의 자원 제약으로 기존 침입 탐지 시스템은 구동이 불가능함.

클라우드 전송 없이 기기 자체에서 위협을 차단하고,
최소한의 메모리와 배터리 소모로 실시간 추론을 구현

데이터 파이프라인 및 전처리

Dataset: CIC-BCCC-NRC ACI-IoT-2023

RAW DATA	→	Label 인코딩 & 로그 변환	→	Z-score 정규화 적용	→	SMOTE
		데이터 분포 보정		스케일 통일		오버 샘플링으로 클래스 불균형 해소

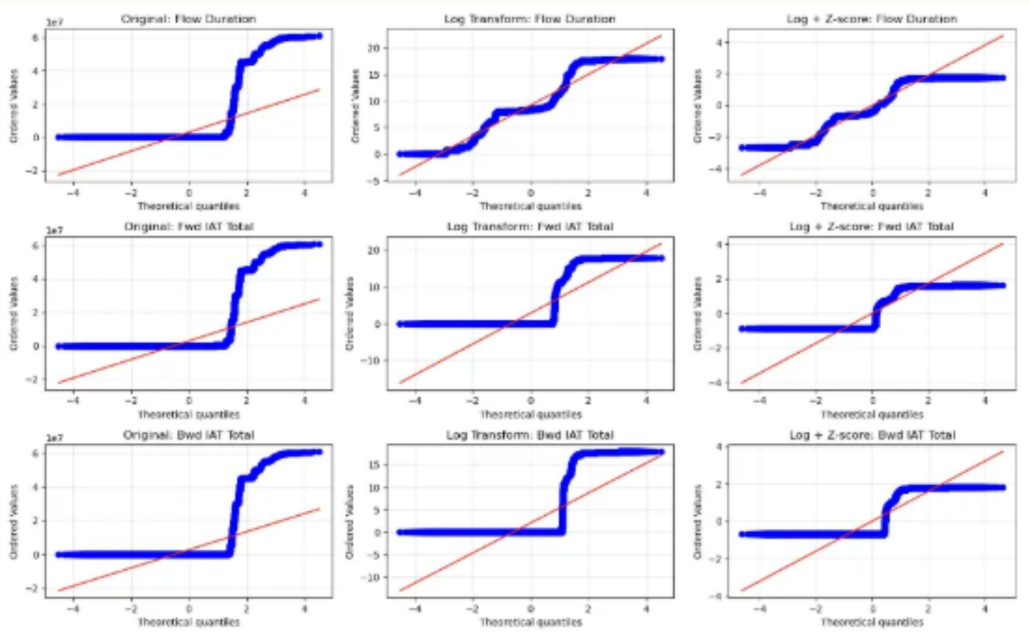

네트워크 데이터 셋으로 데이터 불균형이 관찰되었음
해결을 위하여 Log변환, 정규화를 도입. 기존 데이터에
비하여 분포가 완화되었음을 확인

```
Before Oversampling (70% data):
Is Malicious
1    444838
0     60662
Name: count, dtype: int64

After Oversampling (70% data):
Is Malicious
1    444838
0    444838
Name: count, dtype: int64
```

SMOTE 오버샘플링을 통하여
클래스 분포 조절: 데이터 균형을 확보

모델 선정: 성능과 효율성 분석

모델 Size 비교

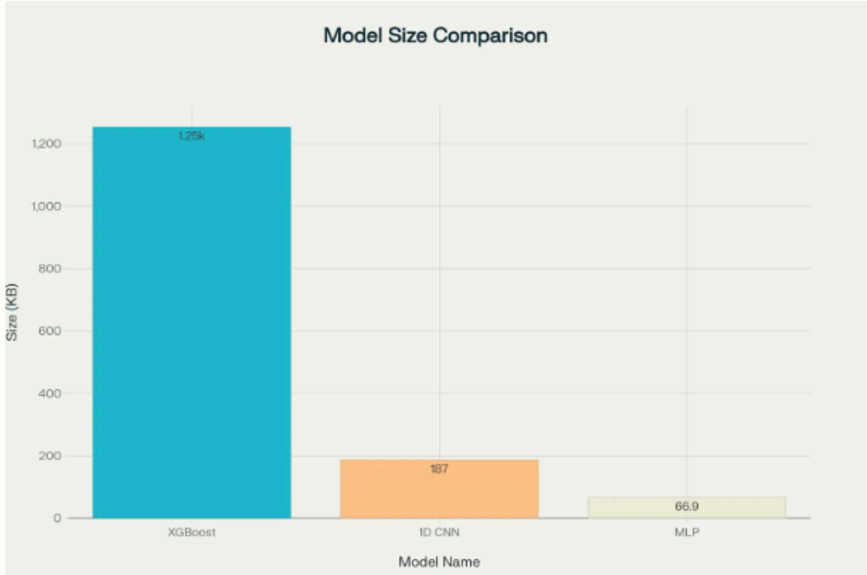

모델 ROC-AUC 비교

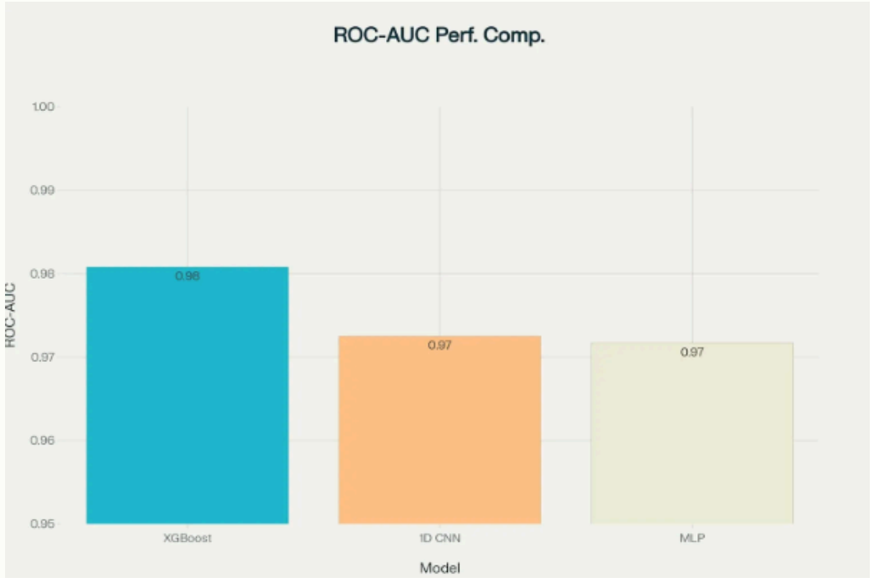

Model	ROC-AUC	Size	Verdict
XGBoost	0.981	1220KB	부적합(Heavy)
1D CNN	0.9727	187KB	양호
MLP	0.9717	66.9KB	최적

선정 결과

XGBoost: 가장 성능은 우수하나 1.2MB가량으로 매우 무거움
1D CNN: 성능, Size 모두 양호한 결과
MLP: 가장 성능은 낮으나, 제일 가벼운 모델

→ 성능 차이는 1% 미만이지만, 크기 차이는 95% 이상,
경량화가 우선 과제이므로 MLP선정

4단계 경량화 전략(1)

Step 1: 특성 선택 및 PCA

1. 피처 선택

기존 84개의 피처가 존재, MCU(IoT) 타겟이므로
복잡도를 낮추는 과정이 필수(상관계수, 카이제곱)으로 20개 피처 선별

2. PCA 차원축소

선별한 20개 피처에서 PCA를 적용 최종적으로 7개의 주성분으로 축소
전체특성 95% 분산 정보를 보존하면서 차원을 71% 감소

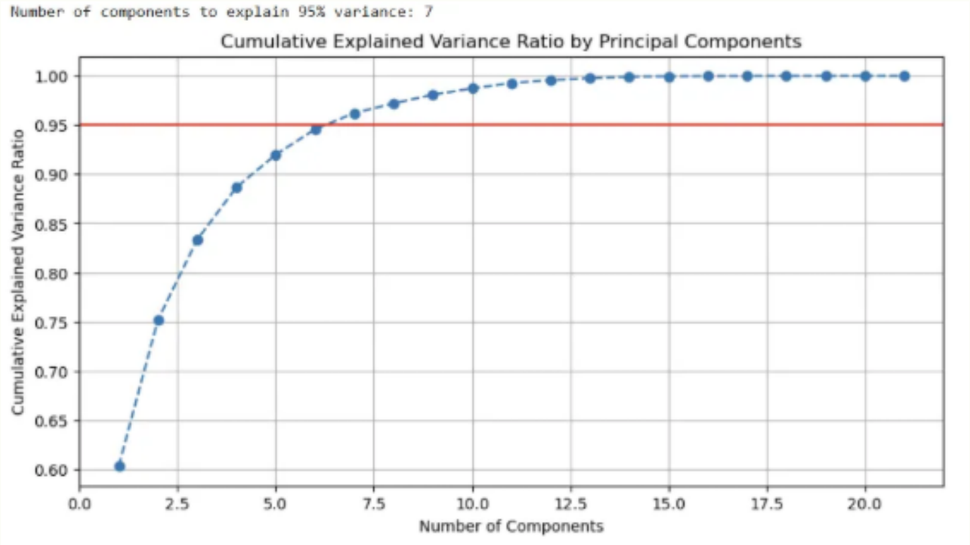

Step 2: 지식 증류

1. 온도 스케일링 (Temperature Scaling)

T=5 적용으로 교사 모델의 Softmax 출력을 부드럽게 평활화
클래스 간 상관관계(Dark Knowledge) 추출

2. 지식 전이 (Knowledge Distillation)

정답 레이블 학습을 넘어 교사 모델의 확률 분포를 학생 모델이 모방
단순 분류를 넘어 모델의 판단 근거까지 학습 유도

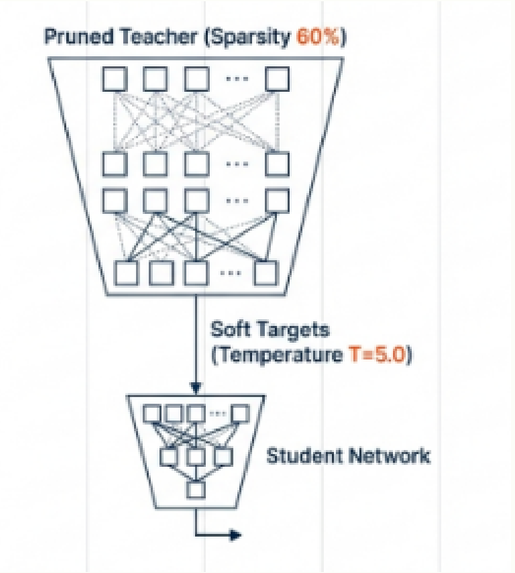

4단계 경량화 전략(2)

Step 3: 점진적 가지치기

1. **PolynomiaDecay Schedule 적용**

학습 진행에 따라 희소성을 0%에서 60% 까지 부드럽게 증가

2. **Magitue Pruning**

가중치의 절대값이 작은(중요도가 낮은) 연결 부터 제거

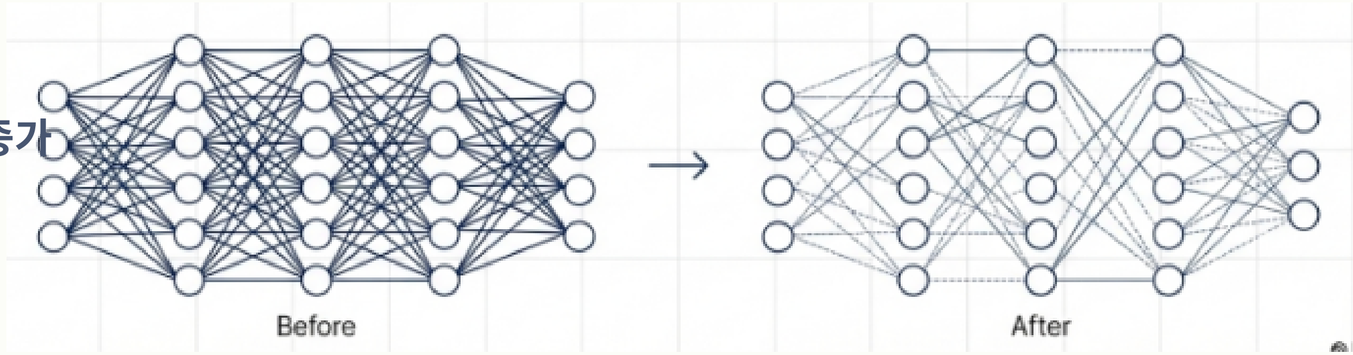

Step 4: 8Bit 정수 양자화

1. **Process**

기존 Float32 가중치를 TensorFlow Lite를 활용
8Bit 정수 비대칭 양자화 변환

2. **Calibration**

대표 데이터셋(Representative Dataset)을 사용하여
양자화 매개변수 최적화 수행

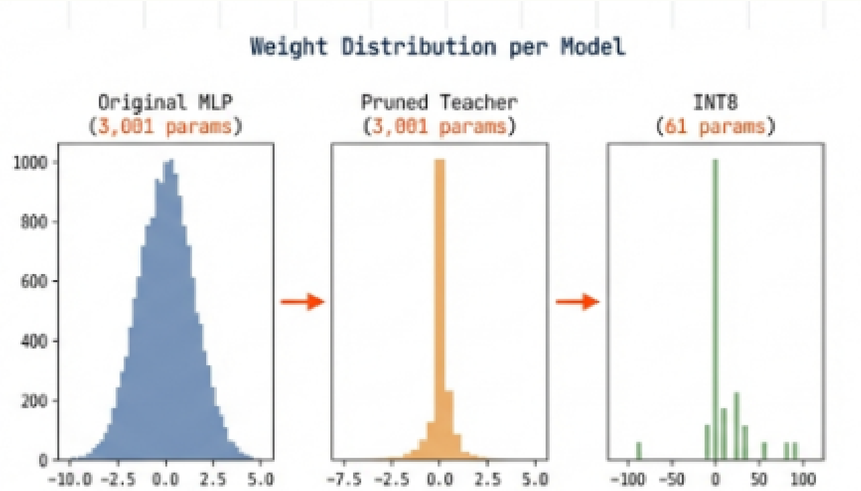

정규분포(Original) → 0 집중(Pruning) → 이산적 분포(Quantization)
로 변화하는 가중치의 모습.

최종 결과: 94% 사이즈 감소와 성능 방어

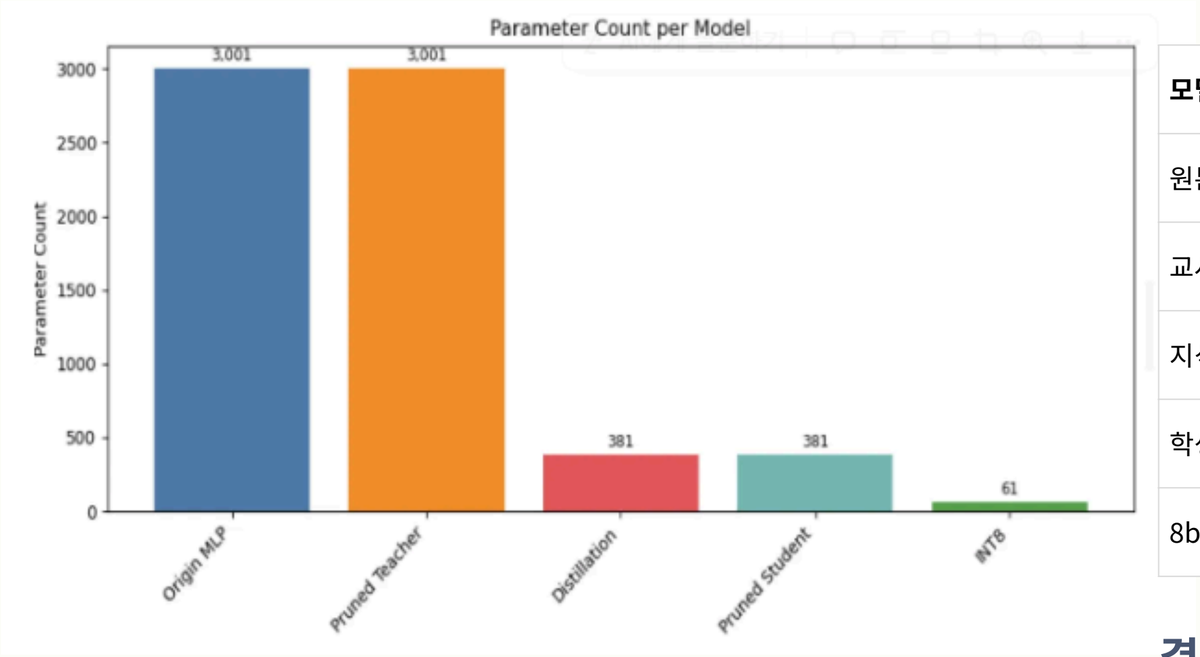

<단계별 파라미터 변화>

모델 유형	ROC_AUC	메모리 사용량(상대)	추론 시간	모델 크기
원본 MLP	0.9717	1	19.43ms	66.9 KB
교사 모델 가지치기	0.9708	0.978	19.30ms	24.7 KB
지식 증류	0.9679	0.977	19.18ms	14.5 KB
학생 모델 가지치기	0.9636	0.955	19.10ms	14.5 KB
8bit 양자화	0.9562	0.822	18.90ms	3.75 KB

결과
ROC-AUC: 0.9717에서 0.9562로 약 1.6% 감소
메모리 사용량: 약 18% 감소
모델 크기: 66.9KB에서 3.75KB로 약 94% 감소
추론 시간: 18.9ms

하드웨어 테스트: Raspberry PI 2 Zero

```
cpu_after: 0.0
cpu_before: 0.0
cpu_after: 0.0
cpu_before: 42.0°C
cpu_after: 0.0
temp_before: 42.9°C
temp_after: 42.9°C

Console log: 1000
```

1000회 실행 기준

```
cpu_after: 0.0
cpu_before: 0.0
cpu_after: 0.5
cpu_before: 41.9°C
cpu_after: 0.5
temp_before: 41.9°C
temp_after: 43.5°C

Console log: 50000
```

50000회 실행 기준

Latency

18.90MS
(실시간 탐지 가능)

Temperture

42.9C → 43.5C
(발열 이슈 없음)

Resource

CPU/Memory 변화 미미

기대효과

현장에서 즉각적인 위협 탐지, 대응
가능한 IoT 생태계 구축

Ultra-Lightweight

3.75KB 모델로 MCU 및 초소형 센서 탑재 가능. 배터리 기반 IoT 기기에서 저전력 장시간 동작.

Privacy-First

데이터가 외부로 나가지 않는 On-Device 보안. 네트워크 탈취 위험 원천 차단.

Independence

별도의 서버나 클라우드 의존 없음. 현장에서 즉각적인 위협 탐지와 대응 가능.

회고 및 향후 과제

배운점

1D CNN/MLP구조 이해 및 경량화 아키텍처 설계

데이터 통계적 선별법(상관계수 + 카이제곱)

온도 파라미터를 활용한 지식 증류 및 손실 함수 구현

향후 개선점

MQTT, CoAP등 IoT 전용 프로토콜 특성 반영하여 모델 고도화